

Matemáticas para Machine Learning



ACTUMLOGOS

DESARROLLANDO HABILIDADES TECNOLÓGICAS


Panorama general y motivación



ACTUMLOGOS

DESARROLLANDO HABILIDADES TECNOLÓGICAS

¿Qué es Machine Learning?



Inteligencia Artificial (AI): Técnica con la que se pretende que las máquinas imiten el comportamiento humano. (¿Inteligencia?)

Aprendizaje de Máquina o **Aprendizaje automático (ML):** Rama de la Inteligencia Artificial que utiliza métodos estadísticos para que las máquinas aprendan de los datos (experiencia).


Redes Neuronales Artificiales (ANN): Rama del Aprendizaje Máquina. Es un sistema computacional inspirado en neuronas biológicas.

Redes neuronales profundas o **Aprendizaje profundo (DNN):** Conjunto de técnicas poderosas para el aprendizaje de redes neuronales (Y sí, redes neuronales más profundas).

Machine Learning, Arthur Samuel (1959): Campo de estudio que dota a las computadoras con la habilidad de aprender sin ser explícitamente programadas.

Problemas de las definiciones anteriores

- Ninguna menciona como funciona realmente machine learning (muy generales, casi mágico...).
- Estas definiciones son ideales para personas que no son estudiantes de ML (es decir, ignoran completamente el tema).
- Como estudiante de ML, eso no es lo que ustedes realmente quieren hacer.



Definición de Machine Learning para el curso

Machine learning no es más que
un problema geométrico...

Y YA!



Ejemplo: Regresión

- Ajustar una línea o curva
- Algunos estadísticos consideran que ML es simplemente un ajuste de curvas glorificado.

$$\hat{y} = mx + b$$



¿Cómo hacer eso en el mundo real?


- Recolectar pares de datos $\{(x_1, y_1), (x_2, y_2), \dots (x_N, y_N)\}$
- Dibujar los puntos en un papel cuadrulado.
- Dibujar una línea a través de los puntos

Empleado	Años	Salario
Iker 1	1	2,000
Iker 2	2	4,000
Iker 3	3	6,000



Agregando un poco de complejidad

- 2 maneras de hacer el problema más complicado
- #1- Tener más características de entrada
 - Nivel de educación (licenciatura, maestría, doctorado, etc.)
 - Escuela, ciudad, edad, género, etc.
- #2- Hacer los objetivos (targets) no lineales.



Ejemplo: Clasificación

- Regresión: predecir un número.
- Clasificación: predecir una categoría/etiqueta
- Ejemplo: Clasificar perros y gatos
 - Dada una imagen (de un perro/gato) predecir si la imagen es perro o gato.






Ejemplo de Clasificación

- Se desea predecir el riesgo de padecer una enfermedad cardiovascular dada la altura y el peso de los pacientes.


ID del paciente	Altura (ft)	Peso (lb)	Riesgo?
1	6	300	1
2	5.5	150	0
3	5.2	175	1
4	5.10	185	0

Ejemplo de Clasificación




Ejemplo: Agrupamiento (Clustering)

- En regresión, se busca que la línea se encuentre lo más cerca posible de los datos.
- En clasificación, se utiliza una línea para separar datos de diferente clases.
- En agrupamiento, se busca agrupar datos que posean características similares



Ejemplo: Aprendizaje por Refuerzo

- El robot puede moverse izquierda, derecha, arriba y abajo (acciones).
- Cada cuadro blanco representa un estado.
- Cada vez que el robot se mueva recibe una recompensa de -1
- Si llega a la meta (color verde) recibe una recompensa de 1000 y se reinicia el juego. Por el otro lado, si llega al estado de fuego (color rojo) recibe una recompensa de -10 y se reinicia el juego.
- Objetivo: maximizar la recompensa



Esto se le conoce como un problema de “Planning” y también representa **un problema de geometría**.

¿Es necesario aprender la teoría de ML para implementar sus algoritmos?



Ejemplo: Teorema de Contracción de Banach

Teorema. Sea (X, d) un espacio métrico. Luego el mapeo $T : X \rightarrow X$ es conocido como mapeo de contracción en X si existe $\Gamma \in [0, 1)$ tal que $d(T(x), T(y)) \leq \Gamma d(x, y)$.




¿Es necesario aprender la matemática de ML?

Ejemplo: Neurona Perceptron




$$y = f(\mathbf{w}^T \mathbf{x} + b)$$

Abrir la caja negra de ML



Queremos entender el misterio de ML...



Sugerencias de Estudiantes

Métodos de optimización.			
Regresiones lineales			
Comprobaciones matemáticas para el desarrollo de autómatas y lenguaje natural.			
Gradient Descent, Funciones de Activación, Backpropagation Error			
Árboles binarios			
Combinatoria, Gradiente descendiente, prueba de hipótesis.			
Análisis de correlaciones para variables categóricas. Análisis ANOVA			
Funciones de optimización, matemáticas para svm y los de probabilidad para hacer árboles de decisión			
Optimización			
Pruebas para validar los modelos			
álgebra lineal, calculo vectorial, probabilidad y estadísticas.			
Álgebra lineal			
el funcionamiento de los optimizadores (Adam, RMSprop),			
Derivada, trigonometría, Calculo diferencia			
Gradiente descendiente			
Fourier series, Discrete Fourier transform, Time-frequency analysis via windowing, Wavelets, https://cds.nyu.edu/math-tools/			
Álgebra Lineal			
Métodos funcionales para el análisis de convergencia de redes neuronales			
Entender la matemática detrás del Descenso por gradiente y los optimizadores usados en Deep Learning, poder diferenciarlos a un nivel conceptual. Por ejemplo saber porque un optimizador de tipo Adam me arroja mejores resultados que un Adamax u cu			
La matemática detrás de la selección de los "Features" más significativos tras aplicar un PCA			
La transformación del Kernel para un SVM			
Cómo funciona el boosting de xgboost y gradient boosting			
La entropía en los algoritmos basados en Árboles de decisión			
Álgebra lineal, límites, geometría analítica , álgebra, probabilidad, estadística inferencial.			
Desigualdad de Hoeffding como aprender de los datos			
Me gustaria que el curso sea 50 teoria y 50 practica de lo que se esta viendo, i.e. en regresión lineal ver los fundamentos matematicos en que se basa la regresión lineal y asi con las demas tecnicas tanto de aprendizaje supervisado como no supervisado			
Gradiente descendiente			
Máquinas de soporte vectorial, los multiplicadores de Lagrange			
Cálculo vectorial			
Los conceptos y formulas de calculo y estadística de			
álgebra lineal			
SVD, álgebra lineal, regresiones lineales			

Conclusiones

- ML (bajo la perspectiva del instructor) es simplemente resolver un problema geométrico.
- ML no le interesa saber qué representan los datos, es decir, todos los datos son iguales.
- En un enfoque práctico, no es necesario conocer a profundidad la teoría oculta de ML.
- Conocer las matemáticas que utilizan los algoritmos de ML es necesario para poder resolver problemas prácticos e identificar rápidamente errores de implementación.

Fundamentos de Álgebra Lineal




ACTUMLOGOS

DESARROLLANDO HABILIDADES TECNOLÓGICAS

Conjuntos

Un conjunto es una colección bien definida de objetos, entendiendo que dichos objetos pueden ser cualquier cosa: números, letras, países, otros conjuntos, etc.



$$\mathbb{N} = \{1, 2, 3, \dots\}$$

$$\mathbb{Z} = \{\dots, -1, 0, 1, \dots\}$$

$$\mathbb{Q} = \left\{ \frac{a}{b} \mid a, b \in \mathbb{Z}, b \neq 0 \right\}$$

$$\mathbb{R} \in (-\infty, \infty)$$



$$\mathbb{I} = \mathbb{R} \setminus \mathbb{Q} = \{x \in \mathbb{R} \mid x \notin \mathbb{Q}\}$$

$$Im = \{\pm\sqrt{-a} \mid a \in \mathbb{R}^+\}$$

$$\mathbb{C} = \mathbb{R} \cup Im$$

Vectores geométricos

- Vectores geométricos son segmentos direccionados que pueden ser dibujados (en al menos dos dimensiones). Su notación particular es $\mathbf{x} \in \mathbb{R}^n$ donde n representa el número de dimensiones.
- Los vectores geométricos pueden ser sumados tal que $\mathbf{x} + \mathbf{y} = \mathbf{z}$ es otro vector, donde $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^n$.
- Más aún, la multiplicación por un escalar $\lambda \mathbf{x}$, $\lambda \in \mathbb{R}$ también es un vector.



Sistemas de Ecuaciones Lineales



ACTUMLOGOS

DESARROLLANDO HABILIDADES TECNOLÓGICAS

Sistema de Ecuaciones Lineales

La forma general de un sistema de ecuaciones lineales es

$$a_{11}x_1 + \cdots + a_{1n}x_n = b_1$$

$$\vdots$$

$$a_{m1}x_1 + \cdots + a_{mn}x_n = b_m$$

$$a_{ij}, b_i \in \mathbb{R}, (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$$
$$i = 1, 2, \dots, m, j = 1, 2, \dots, n$$

Ejemplos

Resolver los siguientes sistemas de ecuaciones

$$\begin{array}{rclcl} \text{a)} & x_1 & + & x_2 & + & x_3 & = & 3 \\ & x_1 & - & x_2 & + & 2x_3 & = & 2 \\ & 2x_1 & & & + & 3x_3 & = & 1 \end{array}$$

SOL. No tiene solución.

$$\begin{array}{rclcl} \text{b)} & x_1 & + & x_2 & + & x_3 & = & 3 \\ & x_1 & - & x_2 & + & 2x_3 & = & 2 \\ & & & x_2 & + & x_3 & = & 2 \end{array}$$

SOL. $\mathbf{x} = (x_1, x_2, x_3) = (1, 1, 1)$

$$\begin{array}{rclcl} \text{c)} & x_1 & + & x_2 & + & x_3 & = & 3 \\ & x_1 & - & x_2 & + & 2x_3 & = & 2 \\ & 2x_1 & & & + & 3x_3 & = & 5 \end{array}$$

SOL. Infinitas soluciones. Sol. general

$$\mathbf{x} = \left(\frac{5}{2} - \frac{3}{2}a, \frac{1}{2} + \frac{1}{2}a, a \right)$$

$$a \in \mathbb{R}$$

Reto: En 5 minutos, complete el código Reto 01 ejercicio 1 y 2. Obtenga la solución del sistema de ecuaciones

Tips:

- Investigue la librería `linalg` de `numpy`
- Utilice los comandos `vstack` y `hstack`
- Investigue para que se usa el comando `lstsq`

```
[[ 1  1  1  3]
 [ 1 -1  2  2]
 [ 2  0  3  5]]
```

La solución es

```
array([4.45961819e+00, 1.45320528e+00, 3.12145137e-16])
```

Resultado Esperado:

```
[[ 1  1  1  3]
 [ 1 -1  2  2]
 [ 2  0  3  1]]
```

No tiene solución

```
[[ 1  1  1  3]
 [ 1 -1  2  2]
 [ 0  1  1  2]]
```

La solución es

```
array([[1.],
       [1.],
       [1.]])
```

Solución:

```
import numpy as np
import numpy.linalg as npl
```

```
A = np.vstack([[1,1,1],[1,-1,2],[2,0,3]])
b = np.vstack([3,2,1])
```

```
A = np.vstack([[1,1,1],[1,-1,2],[0,1,1]])
b = np.vstack([3,2,2])
print(np.hstack([A,b]))
print("La solución es")
npl.solve(A,b)
```

```
print("La solución es")
npl.lstsq(A,b,rcond= None)[3]
```

Matrices



ACTUMLOGOS

DESARROLLANDO HABILIDADES TECNOLÓGICAS

Matrices

Para resolver sistemas de ecuaciones se introduce la siguiente notación


$$x_1 \begin{bmatrix} a_{11} \\ \vdots \\ a_{m1} \end{bmatrix} + x_2 \begin{bmatrix} a_{12} \\ \vdots \\ a_{m2} \end{bmatrix} + \cdots + x_n \begin{bmatrix} a_{1n} \\ \vdots \\ a_{mn} \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix}$$


$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & & a_{mn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix}$$

$$\mathbf{Ax} = \mathbf{b}, \quad \mathbf{A} \in \mathbb{R}^{m \times n}, \quad \mathbf{b} \in \mathbb{R}^m, \quad \mathbf{x} \in \mathbb{R}^n$$

Representacion alternativa

Una matriz de $m \times n$ puede ser representada de forma equivalente como un vector largo. Esto se le conoce como vectorizar una matriz $\text{vec}(A) \in \mathbb{R}^{mn}$, $A \in \mathbb{R}^{m \times n}$



En ML, la vectorización es conocida como aplanado o flatten.

Suma y multiplicación de matrices

La suma de dos matrices $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n}$ es definida como la suma individual de sus elementos

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} a_{11} + b_{11} & \cdots & a_{1n} + b_{1n} \\ \vdots & & \vdots \\ a_{m1} + b_{m1} & & a_{mn} + b_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n}$$

Para el producto de dos matrices $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{B} \in \mathbb{R}^{n \times k}$, los elementos c_{ij} del producto $\mathbf{C} = \mathbf{AB} \in \mathbb{R}^{m \times k}$ se calculan mediante

$$c_{ij} = \sum_{l=1}^n a_{il}b_{lj}, \quad i = 1, \dots, m, \quad j = 1, \dots, k.$$

Notas de la Multiplicación de matrices

- Sólo puede realizarse si las dimensiones donde se realiza la multiplicación coincidan. E.g., para $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{B} \in \mathbb{R}^{n \times k}$

$$\mathbf{C} = \mathbf{AB} \in \mathbb{R}^{m \times k}$$

$$\mathbf{C} = \mathbf{BA} \quad \text{NO ES POSIBLE, LAS DIMENSIONES NO COINCIDEN}$$

- No es conmutativa en la mayoría de los casos, es decir, $\mathbf{AB} \neq \mathbf{BA}$.
- No está definida para multiplicaciones elemento por elemento, i.e., $c_{ij} \neq a_{ij}b_{ij}$
- Multiplicación elemento por elemento aparece en lenguajes de programación que realizan multiplicaciones de arreglos multidimensionales y es conocida como producto de Hadamard.

Ejemplos

Para $\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 3 & 2 & 1 \end{bmatrix} \in \mathbb{R}^{2 \times 3}$, $\mathbf{B} = \begin{bmatrix} 0 & 2 \\ 1 & -1 \\ 0 & 1 \end{bmatrix} \in \mathbb{R}^{3 \times 2}$, calcular

$$\mathbf{AB} = \begin{bmatrix} 1 & 2 & 3 \\ 3 & 2 & 1 \end{bmatrix} \begin{bmatrix} 0 & 2 \\ 1 & -1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 3 \\ 2 & 5 \end{bmatrix} \in \mathbb{R}^{2 \times 2}$$

$$\mathbf{BA} = \begin{bmatrix} 0 & 2 \\ 1 & -1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 3 \\ 3 & 2 & 1 \end{bmatrix} = \begin{bmatrix} 6 & 4 & 2 \\ -2 & 0 & 2 \\ 3 & 2 & 1 \end{bmatrix} \in \mathbb{R}^{3 \times 3}$$

Reto en 5 min complete el código Reto 01 ejercicio 3.
Calcule el producto de matrices anterior usando Python:

Resultado Esperado:

Tips:

- Utilice el comando matrix para crear las matrices.
- Investigue el uso de dot y @ para calcular el producto de matrices

El producto AB es:

```
[[2 3]
 [2 5]]
```

El producto BA es:

```
[[ 6  4  2]
 [-2  0  2]
 [ 3  2  1]]
```

Solución:

```
#Definir las matrices
```

```
A = np.matrix([[1,2,3],[3,2,1]])
```

```
B = np.matrix([[0,2],[1,-1],[0,1]])
```

```
# Calcular el producto de matrices
```

```
AB = np.dot(A,B)
```

```
BA = np.dot(B,A)
```

```
print("El producto AB es: ")
```

```
print(AB)
```

```
print("El producto BA es: ")
```

```
print(BA)
```

```
print(A@B)
```

```
print(B@A)
```

Matriz Identidad

La matriz identidad se define como

$$I_n := \begin{bmatrix} 1 & 0 & \dots & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 & \dots & 1 \end{bmatrix} \in \mathbb{R}^{n \times n}$$

Propiedades de matrices

Una vez definidas la suma y multiplicación de matrices, y la matriz identidad, entonces se puede definir las siguientes propiedades de matrices

- Asociatividad

$$\forall \mathbf{A} \in \mathbb{R}^{m \times n}, \mathbf{B} \in \mathbb{R}^{n \times p}, \mathbf{C} \in \mathbb{R}^{p \times q} : (\mathbf{AB})\mathbf{C} = \mathbf{A}(\mathbf{BC})$$

- Distributividad

$$\begin{aligned} \forall \mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n}, \mathbf{C}, \mathbf{D} \in \mathbb{R}^{n \times p} : (\mathbf{A} + \mathbf{B})\mathbf{C} &= \mathbf{AC} + \mathbf{BC} \\ \mathbf{A}(\mathbf{C} + \mathbf{D}) &= \mathbf{AC} + \mathbf{AD} \end{aligned}$$

- Multiplicación con la matriz identidad

$$\forall \mathbf{A} \in \mathbb{R}^{m \times n} : \mathbf{I}_m \mathbf{A} = \mathbf{A} \mathbf{I}_n = \mathbf{A}$$

Matriz inversa y transpuesta

Inversa. Considere una matriz cuadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$. Sea una matriz $\mathbf{B} \in \mathbb{R}^{n \times n}$ que cumple con la propiedad $\mathbf{AB} = \mathbf{I}_n = \mathbf{BA}$. Entonces $\mathbf{B}$ se le conoce como inversa de $\mathbf{A}$ y se denota como $\mathbf{A}^{-1}$.

Transpuesta. Para una matriz $\mathbf{A} \in \mathbb{R}^{m \times n}$ la matriz $\mathbf{B} \in \mathbb{R}^{n \times m}$ con $b_{ij} = a_{ji}$ se le llama transpuesta de $\mathbf{A}$ y se denota como $\mathbf{B} = \mathbf{A}^\top$.

Simétrica. Una matriz cuadrada se dice que es simétrica si $\mathbf{A} = \mathbf{A}^\top$.

Propiedades las matrices inversas y transpuestas

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{I} = \mathbf{A}^{-1}\mathbf{A}$$

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}$$

$$(\mathbf{A} + \mathbf{B})^{-1} \neq \mathbf{A}^{-1} + \mathbf{B}^{-1}$$

$$(\mathbf{A}^{\top})^{\top} = \mathbf{A}$$

$$(\mathbf{A} + \mathbf{B})^{\top} = \mathbf{A}^{\top} + \mathbf{B}^{\top}$$

$$(\mathbf{AB})^{\top} = \mathbf{B}^{\top}\mathbf{A}^{\top}$$

Multiplicación por un escalar

Para $\alpha, \beta \in \mathbb{R}$ lo siguiente se satisface

- Asociatividad

$$(\alpha\beta)\mathbf{C} = \alpha(\beta\mathbf{C}), \quad \mathbf{C} \in \mathbb{R}^{m \times n}$$

$$\alpha(\mathbf{BC}) = (\alpha\mathbf{B})\mathbf{C} = (\mathbf{BC})\alpha, \quad \mathbf{B} \in \mathbb{R}^{m \times n}, \quad \mathbf{C} \in \mathbb{R}^{n \times k}$$

$$(\alpha\mathbf{C})^\top = \mathbf{C}^\top \alpha = \alpha\mathbf{C}^\top$$

- Distributividad

$$(\alpha + \beta)\mathbf{C} = \alpha\mathbf{C} + \beta\mathbf{C}, \quad \mathbf{C} \in \mathbb{R}^{m \times n}$$

$$\alpha(\mathbf{B} + \mathbf{C}) = \alpha\mathbf{B} + \alpha\mathbf{C}, \quad \mathbf{B}, \mathbf{C} \in \mathbb{R}^{m \times n}$$

Reto: en 5 min complete el código Reto 01 ejercicio 4 y 5 correspondiente a la inversión de matrices y propiedad de distributividad.

Tips:

- Utilice el comando matrix para definir las matrices.
- Investigue para que sirve el comando all().

Resultado Esperado:

```
[[1 0 0]
 [0 1 0]
 [0 0 1]]
[[1 0 0]
 [0 1 0]
 [0 0 1]]
True
```

```
[[ 5 10]
 [15 20]]
True
```

Solución:

```
# Definir las matrices

A = np.matrix([[1,2,1],[4,4,5],[6,7,7]])
B = np.matrix([[-7,-7,6],[2,1,-1],[4,5,-4]])

# Calcular el producto
print(A*B)
print(B*A)

#Verificar que ambas matrices son inversa de cada una
(A*B == (B*A)).all() == ((B*A) == np.eye(A.shape[0])).all()
```

```
D = np.dot((alpha+beta), C)

# Sea D1 = alpha*C y D2 = beta*C
D1 = np.dot(alpha, C)
D2 = np.dot(beta, C)
print(D)

# Son iguales ?
(D == D1+D2).all()
```

Solución de Sistemas de Ecuaciones Lineales



ACTUMLOGOS

DESARROLLANDO HABILIDADES TECNOLÓGICAS

Solución de Sistemas de Ecuaciones Lineales

Para encontrar la solución general de sistemas ecuaciones lineales se debe realizar los siguientes 3 pasos

1. Encontrar una solución particular a $\mathbf{Ax}=\mathbf{b}$.
2. Encontrar todas las soluciones de $\mathbf{Ax}=\mathbf{0}$.
3. Combinar las soluciones del paso 1. y 2.

Reto en 10 minutos analicen junto con el instructor el Reto 02 para resolver sistemas de ecuaciones y obtener la solución general

Tips:

- Analicen con cuidado cada paso.
- Si surge alguna duda pregunte al instructor con confianza.

Resultado Esperado:

$$\left\{ \mathbf{x} \in \mathbb{R}^4 := \mathbf{x} = \begin{bmatrix} 42 \\ 8 \\ 0 \\ 0 \end{bmatrix} + \lambda_1 \begin{bmatrix} 8 \\ 2 \\ -1 \\ 0 \end{bmatrix} + \lambda_2 \begin{bmatrix} -4 \\ 12 \\ 0 \\ -1 \end{bmatrix}, \lambda_1, \lambda_2 \in \mathbb{R} \right\}$$

Transformaciones Elementales

Las transformaciones elementales son pieza fundamental para resolver sistemas de ecuaciones lineales que preservan la solución pero que transforma el sistema de ecuaciones en una forma más simple.

- Intercambio de renglones en la matriz.
- Multiplicación de un renglón por una constante $\lambda \in \mathbb{R} \setminus \{0\}$
- Suma de renglones.

Reto: En 10 minutos complete el Reto 03 utilizando transformaciones elementales y obtenga la solución general.

Tips:

- Siga las instrucciones guía en el Reto.
- Para obtener la solución general siga los pasos establecidos en el reto anterior.

Resultado Esperado:

$$\left\{ \mathbf{x} \in \mathbb{R}^5 : \mathbf{x} = \begin{bmatrix} 2 \\ 0 \\ -1 \\ 1 \\ 0 \end{bmatrix} + \lambda_1 \begin{bmatrix} 2 \\ 1 \\ 0 \\ 0 \\ 0 \end{bmatrix} + \lambda_2 \begin{bmatrix} 2 \\ 0 \\ -1 \\ 2 \\ 1 \end{bmatrix}, \lambda_1, \lambda_2 \in \mathbb{R} \right\}$$

Solución:

```
# Usar una a cualquiera y construir la matrix extendida
a = 100
A = np.vstack([[-2,4,-2,-1,4],[4,-8,3,-3,1],[1,-2,1,-1,1],[1,-2,0,-3,4]])
b = np.vstack([-3,2,0,a])
Ab = np.hstack([A,b])
print(Ab)
```

```
# Intercambiar los renglones R1 con R3
Ab[[0,2]] = Ab[[2,0]]
print(Ab)
```

```
# Aplicando las transformaciones elementales en el renglon 2,3,4
Ab[1] -= 4*Ab[0]    # Renglon 2
Ab[2] += 2*Ab[0]    # Renglon 3
Ab[3] -= Ab[0]      # Renglon 4
print(Ab)
```



```
# Primer transformacion elemental
Ab[3] += -Ab[1] - Ab[2] #R4-R2-R3
print(Ab)
```

```
# Segunda transformacion elemental
Ab[1] *= -1 # R2*-1
Ab = Ab.astype(float) # Convertir la matriz a flotante
Ab[2] *= -1/3 # R2*(-1/3)
print(Ab)
```

```
# Las soluciones son
sol1 = np.array([2,0,-1,1,0])
cero1 = np.array([2,1,0,0,0])
cero2 = np.array([2,0,-1,2,1])

lambda1 = 456
lambda2 = -8763
sol = sol1 + lambda1*cero1 + lambda2*cero2
# El producto de la matriz original A con el vector solucion sol debe ser i
bsol = np.dot(A,sol)
print(bsol)
```

Forma escalonada

Una matriz está en su forma escalonada si:

- Todos los renglones que contienen ceros se encuentran al fondo de la matriz; de manera equivalente, todos los renglones que contengan al menos un elemento que no sea cero se encuentran en la parte superior de los renglones que contienen cero.
- Observando únicamente a los renglones con elementos diferentes de cero, el primer número diferente de cero hacia la izquierda (también conocido como pivote) se encuentra siempre a la derecha del pivote del renglón que se encuentra arriba de el.

Forma escalonada

- La matriz se encuentra en su forma escalonada reducida si: se encuentra en la forma escalonada, cada pivote es 1 y todos los otros elementos son cero.
- Eliminación Gaussiana (**Gauss-Jordan**) es un algoritmo que realiza transformaciones elementales para llevar al sistema de ecuaciones en su forma escalonada reducida.

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 1 & -1 \\ 0 & 0 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Reto: En 10 minutos complete el ejercicio 1 del Reto 04 para determinar si una matriz se encuentra en su forma escalonada reducida.

Resultado Esperado:

Tips:

- Siga las instrucciones del reto.
- Puede usar sympy o numpy para crear las matrices.

$$\left\{ \mathbf{x} \in \mathbb{R}^5 : \mathbf{x} = \lambda_1 \begin{bmatrix} -3 \\ 1 \\ 0 \\ 0 \\ 0 \end{bmatrix} + \lambda_2 \begin{bmatrix} -3 \\ 0 \\ -9 \\ 4 \\ 1 \end{bmatrix} \mid \lambda_1, \lambda_2 \in \mathbb{R} \right\}$$

$$\left\{ \mathbf{x} \in \mathbb{R}^5 : \mathbf{x} = \lambda_1 \begin{bmatrix} 3 \\ -1 \\ 0 \\ 0 \\ 0 \end{bmatrix} + \lambda_2 \begin{bmatrix} 3 \\ 0 \\ 9 \\ -4 \\ -1 \end{bmatrix} \mid \lambda_1, \lambda_2 \in \mathbb{R} \right\}$$

Solución:

```
import numpy as np
import numpy.linalg as nlp
import matplotlib.pyplot as plt
from sympy import *
```

```
A = Matrix([[1,3,0,0,3],[0,0,1,0,9],[0,0,0,1,-4]])
A
```

```
A_ref = A.rref()
A_ref
```

```
# Verificamos que la solución satisfaga  $Ax=0$ 
lambda1 = 45675
lambda2= 788665
sol1 = np.dot(A,lambda1*np.vstack([-3,1,0,0,0])+lambda2*np.vstack([-3,0,-9,4,1]))
sol1
```

El truco del menos 1

- Es un truco bastante práctico para poder leer la solución general de un sistema de ecuaciones lineales homogéneas $A\mathbf{x}=\mathbf{0}$, donde $A \in \mathbb{R}^{k \times n}$, $\mathbf{x} \in \mathbb{R}^n$.
- Para comenzar se asume que la matriz A se encuentra en su forma escalonada reducida, i.e.,

$$A = \begin{bmatrix} 0 & \cdots & 0 & \mathbf{1} & * & \cdots & * & 0 & * & \cdots & * & 0 & * & \cdots & * \\ \vdots & & \vdots & 0 & 0 & \cdots & 0 & \mathbf{1} & * & \cdots & * & \vdots & \vdots & & \vdots \\ \vdots & & \vdots & \vdots & \vdots & & \vdots & 0 & \vdots & & \vdots & \vdots & \vdots & & \vdots \\ \vdots & & \vdots & \vdots & \vdots & & \vdots & \vdots & \vdots & & \vdots & 0 & \vdots & & \vdots \\ 0 & \cdots & 0 & 0 & 0 & \cdots & 0 & 0 & 0 & \cdots & 0 & \mathbf{1} & * & \cdots & * \end{bmatrix}$$

- El truco consiste en extender la matriz A a una matriz de tamaño $n \times n$ al añadir un total de $n - k$ renglones de la forma $[0 \ \cdots \ 0 \ -1 \ 0 \ \cdots \ 0]$ tal que en la diagonal únicamente se tenga 1s o -1s.

Reto: En 5 minutos complete el ejercicio 2 del Reto 04 para visualizar el truco del menos 1.

Resultado Esperado:

Tips:

- Busque para que sirve el comando copy e insert.

```
array([[1, 3, 0, 0, 3],  
       [0, -1, 0, 0, 0],  
       [0, 0, 1, 0, 9],  
       [0, 0, 0, 1, -4],  
       [0, 0, 0, 0, -1]], dtype=object)
```

Solución:

```
A2 = A.copy()
```

```
A2
```

```
# Agregamos los renglones [0,...,0,-1,0,...,0]  
A2 = np.insert(A2,1,np.hstack([0,-1,0,0,0]),0)  
A2 = np.insert(A2,4,np.hstack([0,0,0,0,-1]),0)  
A2
```


Calcular la inversa

Para calcular la matriz inversa $\mathbf{A}^{-1}$ de $\mathbf{A} \in \mathbb{R}^{n \times n}$ se necesita encontrar una matriz $\mathbf{X}$ que satisfaga $\mathbf{A}\mathbf{X} = \mathbf{I}_n$. Entonces $\mathbf{X} = \mathbf{A}^{-1}$. Podemos escribir este problema como un conjunto de ecuaciones lineales simultáneas donde se resuelve para $\mathbf{X} = [\mathbf{x}_1 | \cdots | \mathbf{x}_n]$. La notación aumentada consiste en obtener la forma escalonada reducida de lado izquierdo y por lo tanto el lado derecho obtener la matriz inversa.

$$[\mathbf{A} | \mathbf{I}_n] \rightsquigarrow \cdots \rightsquigarrow [\mathbf{I}_n | \mathbf{A}^{-1}]$$

Reto: En 5 minutos complete el ejercicio 3 del Reto 04 y obtenga la matriz inversa usando eliminación Gaussiana,

Tips:

- Siga las instrucciones del Reto.
- Investigue cómo calcular la matriz inversa usando sympy y numpy.

Resultado Esperado:

$$\begin{bmatrix} -1.0 & 2.0 & -2.0 & 2.0 \\ 1.0 & -1.0 & 2.0 & -2.0 \\ 1.0 & -1.0 & 1.0 & -1.0 \\ -1.0 & 0 & -1.0 & 2.0 \end{bmatrix}$$

$$\begin{bmatrix} -1 & 2 & -2 & 2 \\ 1 & -1 & 2 & -2 \\ 1 & -1 & 1 & -1 \\ -1 & 0 & -1 & 2 \end{bmatrix}$$

$$\begin{bmatrix} [-1. & 2. & -2. & 2.] \\ [1. & -1. & 2. & -2.] \\ [1. & -1. & 1. & -1.] \\ [-1. & 0. & -1. & 2.] \end{bmatrix}$$

Solución:

```
# Creamos la matriz aumentada
Aug = np.hstack([A,I])
# Convertimos la matriz de numpy a sympy
Aug = Matrix(Aug)
Aug
```

```
Aug_ref= Aug.rref()
Aug_ref
```

```
# Obtenemos la matriz inversa
invA = Aug_ref[0][:,A.shape[0]:]
invA
```

```
invA2 = A.inv()
invA2
```

```
---
Anumpy = np.array(A).astype(np.float64)

# Calculo de la inversa
invA3 = npl.inv(Anumpy)
print(invA3)
```

Algoritmo para resolver sistemas de ecuaciones lineales

Para resolver sistemas de ecuaciones lineales de la forma $\mathbf{Ax} = \mathbf{b}$

Si $\mathbf{A} \in \mathbb{R}^{n \times n}$

$$\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$$

Si $\mathbf{A} \in \mathbb{R}^{m \times n}$

$$\mathbf{Ax} = \mathbf{b} \iff \mathbf{A}^\top \mathbf{Ax} = \mathbf{A}^\top \mathbf{b} \iff \mathbf{x} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}$$

Donde $(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top$ es conocida como la pseudo-inversa de Moore-Penrose.

Este algoritmo es la solución de **mínimos cuadrados de mínima norma (Least-mean squares)**

Problemas del algoritmo LMS

- Computacionalmente es muy costoso por el número de multiplicaciones que se debe realizar en la matriz inversa.
- Para sistemas de ecuaciones de alta dimensionalidad, este algoritmo no es conveniente debido a que el número de operaciones se incrementa.

Soluciones:

- Algoritmos recursivos: Gauss Seidel, método de Richardson, el método de Jacobi, aproximaciones sucesivas.

$$\mathbf{x}^{(k+1)} = \mathbf{C}\mathbf{x}^{(k)} + \mathbf{d} \quad \longrightarrow \quad \|\mathbf{x}^{(k+1)} - \mathbf{x}_*\|$$

Espacios Vectoriales



ACTUMLOGOS

DESARROLLANDO HABILIDADES TECNOLÓGICAS

Grupos

Considere un conjunto $\mathcal{G}$ y una operación $\otimes: \mathcal{G} \times \mathcal{G} \rightarrow \mathcal{G}$ definida en $\mathcal{G}$. Entonces $G := (\mathcal{G}, \otimes)$ se le conoce como grupo si se cumple que:

1. Cerradura de $\mathcal{G}$ sobre $\otimes: \forall x, y \in \mathcal{G}: x \otimes y \in \mathcal{G}$.
2. Asociatividad: $\forall x, y, z \in \mathcal{G}: (x \otimes y) \otimes z = x \otimes (y \otimes z)$.
3. Elemento neutro: $\exists e \in \mathcal{G} \forall x \in \mathcal{G}: x \otimes e = x \vee e \otimes x = x$.
4. Elemento inverso: $\forall x \in \mathcal{G} \exists y \in \mathcal{G}: x \otimes y = e \vee y \otimes x = e$.
Generalmente se escribe como x^{-1} para denotar el elemento inverso de x .

Si adicionalmente $\forall x, y \in \mathcal{G}: x \otimes y = y \otimes x$, entonces $G = (\mathcal{G}, \otimes)$ es un grupo Abeliano (conmutativo).

Ejemplos

Determine si los siguientes conjuntos con su respectiva operación asociada son grupos:

- $(\mathbb{Z}, +)$ Grupo
- $(\mathbb{Z}, \cdot)$ No Grupo
- $(\mathbb{R}, \cdot)$ No Grupo
- $(\mathbb{R}^{n \times n}, \cdot)$ Grupo

Considere un conjunto $\mathcal{G}$ y una operación $\otimes: \mathcal{G} \times \mathcal{G} \rightarrow \mathcal{G}$ definida en $\mathcal{G}$. Entonces $G := (\mathcal{G}, \otimes)$ se le conoce como grupo si se cumple que:

1. Cerradura de $\mathcal{G}$ sobre $\otimes$: $\forall x, y \in \mathcal{G}: x \otimes y \in \mathcal{G}$.
2. Asociatividad: $\forall x, y, z \in \mathcal{G}: (x \otimes y) \otimes z = x \otimes (y \otimes z)$.
3. Elemento neutro: $\exists e \in \mathcal{G} \forall x \in \mathcal{G}: x \otimes e = x$ y $e \otimes x = x$.
4. Elemento inverso: $\forall x \in \mathcal{G} \exists y \in \mathcal{G}: x \otimes y = e$ y $y \otimes x = e$.
Generalmente se escribe como x^{-1} para denotar el elemento inverso de x .

Si adicionalmente $\forall x, y \in \mathcal{G}: x \otimes y = y \otimes x$, entonces $G = (\mathcal{G}, \otimes)$ es un grupo Abelian (conmutativo).

Espacios Vectoriales

Un espacio vectorial con valores en los reales $V = (\mathcal{V}, +, \cdot)$ es un conjunto $\mathcal{V}$ con dos operaciones

$$\begin{aligned} +: \mathcal{V} \times \mathcal{V} &\rightarrow \mathcal{V} \\ \cdot: \mathbb{R} \times \mathcal{V} &\rightarrow \mathcal{V} \end{aligned}$$

donde

1. $(\mathcal{V}, +)$ es un grupo Abeliano.
2. Distributividad
 1. $\forall \lambda \in \mathbb{R}, \mathbf{x}, \mathbf{y} \in \mathcal{V}: \lambda \cdot (\mathbf{x} + \mathbf{y}) = \lambda \cdot \mathbf{x} + \lambda \cdot \mathbf{y}$
 2. $\forall \lambda, \psi \in \mathbb{R}, \mathbf{x} \in \mathcal{V}: (\lambda + \psi) \cdot \mathbf{x} = \lambda \cdot \mathbf{x} + \psi \cdot \mathbf{x}$
3. Asociatividad (operación exterior): $\forall \lambda, \psi \in \mathbb{R}, \mathbf{x} \in \mathcal{V}: \lambda \cdot (\psi \cdot \mathbf{x}) = (\lambda\psi) \cdot \mathbf{x}$
4. Elemento neutro respecto a la operación exterior: $\forall \mathbf{x} \in \mathcal{V}: 1 \cdot \mathbf{x} = \mathbf{x}$.

Definiciones

- Los elementos $\mathbf{x} \in V$ se le llaman vectores.
- El elemento neutro de $(V, +)$ es el vector cero $\mathbf{0} = [0, \dots, 0]^T$ y la operación interna $+$ se le conoce como suma de vectores.
- Los elementos $\lambda \in \mathbb{R}$ se denominan escalares y la operación exterior $\cdot$ es la multiplicación por escalares.

Ejemplos


- $V = \mathbb{R}^n$
- $V = \mathbb{R}^{m \times n}$

Subespacios Vectoriales

Sea $V = (\mathcal{V}, +, \cdot)$ un espacio vectorial y $\mathcal{U} \subseteq \mathcal{V}, \mathcal{U} \neq \emptyset$. Entonces $U = (\mathcal{U}, +, \cdot)$ se le llama subespacio vectorial de V (o subespacio lineal) si U es un espacio vectorial con las mismas operaciones $+$ y $\cdot$ restringidas a $\mathcal{U} \times \mathcal{U}$ y $\mathbb{R} \times \mathcal{U}$.

Para determinar si $(\mathcal{U}, +, \cdot)$ es un subespacio vectorial de V se tiene que verificar que



1. $\mathcal{U} \neq \emptyset$, en particular: $\mathbf{0} \in \mathcal{U}$
2. Cerradura de U
 1. Respecto a la operación exterior: $\forall \lambda \in \mathbb{R} \forall \mathbf{x} \in \mathcal{U}: \lambda \mathbf{x} \in \mathcal{U}$
 2. Respecto a la operación interna: $\forall \mathbf{x}, \mathbf{y} \in \mathcal{U}: \mathbf{x} + \mathbf{y} \in \mathcal{U}$





Reto: Analicen junto con el instructor el Reto 05 y determinen si los conjuntos dados son subespacios.

Tips:

- Analice cada propiedad que define un grupo, espacio vectorial y subespacio vectorial.
- Investigue para que sirve el comando quiver y scatter.



Resultado Esperado:



Independencia Lineal



ACTUMLOGOS

DESARROLLANDO HABILIDADES TECNOLÓGICAS


Independencia Lineal

Definición (Combinación Lineal): Considere un espacio vectorial V y un número finito de vectores $\mathbf{x}_1, \dots, \mathbf{x}_k \in V$. Entonces, cada $\mathbf{v} \in V$ de la forma

$$\mathbf{v} = \lambda_1 \mathbf{x}_1 + \dots + \lambda_k \mathbf{x}_k = \sum_{i=1}^k \lambda_i \mathbf{x}_i \in V$$

con $\lambda_1, \dots, \lambda_k \in \mathbb{R}$ es una combinación lineal de los vectores $\mathbf{x}_1, \dots, \mathbf{x}_k$.

Definición ((In)Dependencia Lineal): Considere un espacio vectorial V con $k \in \mathbb{N}$ y $\mathbf{x}_1, \dots, \mathbf{x}_k \in V$. Si existe una combinación no trivial tal que $\mathbf{0} = \sum_{i=1}^k \lambda_i \mathbf{x}_i$ con al menos un escalar $\lambda_i \neq 0$, entonces los vectores $\mathbf{x}_1, \dots, \mathbf{x}_k$ son linealmente dependientes. Si solo existe la solución trivial, i.e., $\lambda_1 = \dots = \lambda_k = 0$ entonces los vectores $\mathbf{x}_1, \dots, \mathbf{x}_k$ son linealmente independientes.



Considere un espacio vectorial V con k vectores linealmente independientes $\mathbf{b}_1, \dots, \mathbf{b}_k$ y m combinaciones lineales

$$\begin{aligned}\mathbf{x}_1 &= \sum_{i=1}^k \lambda_{i1} \mathbf{b}_i \\ &\vdots \\ \mathbf{x}_m &= \sum_{i=1}^k \lambda_{im} \mathbf{b}_i\end{aligned}$$

Definiendo $\mathbf{B} = [\mathbf{b}_1, \dots, \mathbf{b}_k]$ como la matriz cuyas columnas son los vectores linealmente independientes $\mathbf{b}_1, \dots, \mathbf{b}_k$, entonces se puede escribir

$$\mathbf{x}_j = \mathbf{B} \boldsymbol{\lambda}_j, \quad \boldsymbol{\lambda}_j = \begin{bmatrix} \lambda_{1j} \\ \vdots \\ \lambda_{kj} \end{bmatrix}, \quad j = 1, \dots, m$$

Para probar que los vectores son linealmente independientes se utiliza la prueba general $\sum_{j=1}^m \psi_j \mathbf{x}_j = \mathbf{0}$. Entonces

$$\sum_{j=1}^m \psi_j \mathbf{x}_j = \sum_{j=1}^m \psi_j \mathbf{B} \boldsymbol{\lambda}_j = \mathbf{B} \sum_{j=1}^m \psi_j \boldsymbol{\lambda}_j$$

Esto quiere decir que $\{\mathbf{x}_1, \dots, \mathbf{x}_m\}$ son linealmente independientes si y solo si los vectores columna $\{\boldsymbol{\lambda}_1, \dots, \boldsymbol{\lambda}_m\}$ son linealmente independientes.

Reto: En 5 minutos complete los ejercicios 1 y 2 del Reto 06 para entender el concepto de vectores linealmente dependientes e independientes.

Resultado Esperado:

Tips:

- Lea las instrucciones que aparecen en el Reto.
- Utilice los conceptos aprendidos anteriormente.

```
(Matrix([
  [1, 0, 0],
  [0, 1, 0],
  [0, 0, 1],
  [0, 0, 0]]) , (0, 1, 2))
```

```
(Matrix([
  [1, 0, 0, -7],
  [0, 1, 0, -15],
  [0, 0, 1, -18],
  [0, 0, 0, 0]]) , (0, 1, 2))
```


Solución:

```
import numpy as np
from sympy import *
import matplotlib.pyplot as plt
import numpy.linalg as npl
```

```
# Crear los vectores
```

```
x1 = np.vstack([1,2,-3,4])
x2 = np.vstack([1,1,0,2])
x3 = np.vstack([-1,-2,1,1])
```

```
A = np.hstack([x1,x2,x3])
A = Matrix(A)
```

```
A_ref = A.rref()
A_ref
```

```
# Definir matriz
```

```
A = Matrix([[1,-4,2,17],[-2,-2,3,-10],[1,0,-1,11],[-1,4,-3,1]])
# Obtener su forma escalonada reducida
A.rref()
```

Bases y Rango



ACTUMLOGOS

DESARROLLANDO HABILIDADES TECNOLÓGICAS


Bases y Rango

En un espacio vectorial V , estamos interesados en un conjunto de vectores $\mathcal{A}$ que poseen la propiedad de que cualquier vector $v \in \mathcal{V}$ puede ser obtenido mediante la combinación lineal de los vectores en $\mathcal{A}$.

Definición (Conjunto Generador y Span). Considere un espacio vectorial $V = (\mathcal{V}, +, \cdot)$ y un conjunto de vectores $\mathcal{A} = \{\mathbf{x}_1, \dots, \mathbf{x}_k\} \subseteq \mathcal{V}$. Si cada vector $\mathbf{v} \in \mathcal{V}$ puede ser expresado como una combinación lineal de $\mathbf{x}_1, \dots, \mathbf{x}_k$, entonces $\mathcal{A}$ se le conoce como un conjunto generador de $\mathcal{V}$. El conjunto de todas las combinaciones lineales en $\mathcal{A}$ se le denomina span de $\mathcal{A}$. Si $\mathcal{A}$ genera el espacio vectorial V , se escribe como $V = \text{span}[\mathcal{A}]$ o $V = \text{span}[\mathbf{x}_1, \dots, \mathbf{x}_k]$.



Definición (Base). Considere un espacio vectorial $V = (\mathcal{V}, +, \cdot)$ y $\mathcal{A} \subseteq \mathcal{V}$. Un conjunto generador $\mathcal{A}$ de V se le llama mínimo si no existe un conjunto mas pequeño $\tilde{\mathcal{A}} \subseteq \mathcal{A} \subseteq \mathcal{V}$ que genere a V . Cada conjunto generador linealmente independiente de V es mínimo y se le denomina como base de V .



Sea $V = (\mathcal{V}, +, \cdot)$ un espacio vectorial y $\mathcal{B} \subseteq \mathcal{V}, \mathcal{B} \neq \emptyset$. Entonces, los siguientes enunciados son equivalentes:

- $\mathcal{B}$ es una base de V .
- $\mathcal{B}$ es un conjunto generador mínimo.
- $\mathcal{B}$ es un conjunto máximo de vectores linealmente independientes en V , i.e., añadir otro vector al conjunto lo convierte en linealmente dependiente.
- Cada vector $\mathbf{x} \in V$ es una combinación lineal de vectores de $\mathcal{B}$, y cada combinación lineal es única, es decir, con

$$\mathbf{x} = \sum_{i=1}^k \lambda_i \mathbf{b}_i = \sum_{i=1}^k \psi_i \mathbf{b}_i$$

y $\lambda_i, \psi_i \in \mathbb{R}, \mathbf{b}_i \in \mathcal{B}$ donde de la igualdad anterior se cumple que $\lambda_i = \psi_i$.

Consideraciones adicionales

- Cada espacio vectorial posee una base $\mathcal{B}$.
- En ML, únicamente consideramos vectores de dimensión finita.
- En este caso, la dimensión de V es el numero de vectores bases de V , y se denota como $\dim(V)$. Si $U \subseteq V$ es un subespacio de V , entonces $\dim(U) \leq \dim(V)$ y $\dim(U) = \dim(V)$ si y solo si $U = V$.

Calcular el espacio generado

Una base de un subespacio $U = \text{span}[x_1, \dots, x_m] \subseteq \mathbb{R}^n$ puede ser obtenido mediante los siguientes pasos:

1. Escribir los vectores generadores como columnas de una matriz A .
2. Determinar la forma escalonada de A .
3. Los vectores generadores asociado con las columnas pivotes son una base de U .

Rango

El numero de columnas linealmente independientes de una matriz $\mathbf{A} \in \mathbb{R}^{m \times n}$ igual al numero de renglones linealmente independiente es conocido como rango de $\mathbf{A}$ y se denote como $\text{rank}(\mathbf{A})$.

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$\text{rank}(\mathbf{A}) = 3$$

El rango posee las siguientes propiedades:

- $\text{rank}(\mathbf{A}) = \text{rank}(\mathbf{A}^T)$, i.e., el rango por columnas=rango por renglones.
- Las columnas de $\mathbf{A} \in \mathbb{R}^{m \times n}$ generan un subespacio $U \subseteq \mathbb{R}^m$ con $\dim(U) = \text{rank}(\mathbf{A})$. Una base de U puede ser obtenida mediante eliminación Gaussiana de $\mathbf{A}$.
- Los renglones de $\mathbf{A} \in \mathbb{R}^{m \times n}$ generan un subespacio $W \subseteq \mathbb{R}^n$ con $\dim(W) = \text{rank}(\mathbf{A})$. Una base de W puede ser obtenida mediante eliminación Gaussiana de $\mathbf{A}^T$.
- Para toda $\mathbf{A} \in \mathbb{R}^{n \times n}$ se cumple que es regular (invertible) si $\text{rank}(\mathbf{A}) = n$.
- Para toda matriz $\mathbf{A} \in \mathbb{R}^{m \times n}$ y toda $\mathbf{b} \in \mathbb{R}^m$ se mantiene que el sistema de ecuaciones lineal $\mathbf{Ax} = \mathbf{b}$ puede ser resuelto solo si $\text{rank}(\mathbf{A}) = \text{rank}(\mathbf{A}|\mathbf{b})$.
- Para toda matriz $\mathbf{A} \in \mathbb{R}^{m \times n}$ el subespacio de soluciones de $\mathbf{Ax} = \mathbf{0}$ posee dimension $n - \text{rank}(\mathbf{A})$.
- Una matriz $\mathbf{A} \in \mathbb{R}^{m \times n}$ tiene rango completo es el vaor mínimo entre el numero de columnas y renglones, i.e., $\text{rank}(\mathbf{A}) = \min(m, n)$. De lo contrario se dice que es de rango deficiente.

Reto: En 10 minutos complete el Reto 07 para clarificar lo que es un conjunto generador, base y el rango.


Tips:

- Siga las instrucciones del reto.
- Investigue cómo obtener el rango de una matriz usando numpy y sympy.

```
(Matrix([  
  [1, 0, 0],  
  [0, 1, 0],  
  [0, 0, 1],  
  [0, 0, 0]]) , (0, 1, 2))
```

```
[1, 0, -1, 0],  
[0, 1, 2, 0],  
[0, 0, 0, 1],  
[0, 0, 0, 0],  
[0, 0, 0, 0]]) , (0, 1, 3))
```

Resultado Esperado:



Solución:

```
# Caso a)
A = Matrix([[1,0,1],[0,1,1],[0,0,0]])
len(A.rref()[1])
```

```
# Forma alternativa
A.rank()
```

```
#Usando numpy
A_numpy = np.array(A).astype('float64')
nlp.matrix_rank(A_numpy)
```

Mapeos Lineales



ACTUMLOGOS

DESARROLLANDO HABILIDADES TECNOLÓGICAS

Mapeos Lineales

Definición (Mapeo Lineal). Para espacios vectoriales V, W , un mapeo $\Phi: V \rightarrow W$ se le denomina mapeo lineal (homomorfismo del espacio vectorial/ transformación lineal) si

$$\forall \mathbf{x}, \mathbf{y} \in V, \forall \lambda, \psi \in \mathbb{R}: \Phi(\lambda \mathbf{x} + \psi \mathbf{y}) = \lambda \Phi(\mathbf{x}) + \psi \Phi(\mathbf{y})$$

Definición (Inyectiva, Sobreyectiva, Biyectiva). Considere un mapeo $\Phi: \mathcal{V} \rightarrow \mathcal{W}$, donde $\mathcal{V}, \mathcal{W}$ son conjuntos arbitrarios. Entonces Φ se le llama

- Inyectiva si $\forall \mathbf{x}, \mathbf{y} \in \mathcal{V}: \Phi(\mathbf{x}) = \Phi(\mathbf{y}) \Rightarrow \mathbf{x} = \mathbf{y}$.
- Sobreyectiva si $\Phi(\mathcal{V}) = \mathcal{W}$.
- Biyectiva si es inyectiva y sobreyectiva.

Ejemplo (Homomorfismo)

El mapeo $\Phi: \mathbb{R}^2 \rightarrow \mathbb{C}$, $\Phi(\mathbf{x}) = x_1 + ix_2$, es un homomorfismo:

$$\begin{aligned}\Phi\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}\right) &= (x_1 + y_1) + i(x_2 + y_2) = x_1 + ix_2 + y_1 + iy_2 \\ &= \Phi\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) + \Phi\left(\begin{bmatrix} y_1 \\ y_2 \end{bmatrix}\right)\end{aligned}$$

$$\Phi\left(\lambda \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \lambda x_1 + \lambda i x_2 = \lambda(x_1 + ix_2) = \lambda \Phi\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right)$$

Espacios vectoriales de dimensión finita V y W son isomorfos si y sólo si $\dim(V)=\dim(W)$.

Lo anterior quiere decir que existe un mapeo lineal y biyectivo entre dos espacios vectoriales de la misma dimensión. De manera intuitiva, esto quiere decir que dos espacios vectoriales de la misma dimensión son una representación de la misma cosa y que pueden transformarse entre cada uno de ellos sin perder información.

$$\Phi(\mathbb{R}^{m \times n}) = \mathbb{R}^{mn}$$

Representación Matricial de Mapeos Lineales

Cualquier espacio vectorial de dimensión n es isomorfo en $\mathbb{R}^n$. Se considerara una base $\{\mathbf{b}_1, \dots, \mathbf{b}_n\}$ de un espacio vectorial V de orden n .

Notación. A partir de este punto la notación puede que sea un poco confusa. Por lo tanto, es importante establecer las diferencias. $B = (\mathbf{b}_1, \dots, \mathbf{b}_n)$ es una base ordenada, $\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_n\}$ es una base no ordenada, y $\mathbf{B} = [\mathbf{b}_1, \dots, \mathbf{b}_n]$ es una matriz cuyas columnas son los vectores $\mathbf{b}_1, \dots, \mathbf{b}_n$.

Definición (Coordenadas). Considere un espacio vectorial V y una base ordenada $B = (\mathbf{b}_1, \dots, \mathbf{b}_n)$ de V . Para cualquier $\mathbf{x} \in V$ se obtiene una única representación (combinación lineal)

$$\mathbf{x} = \alpha_1 \mathbf{b}_1 + \dots + \alpha_n \mathbf{b}_n$$

de $\mathbf{x}$ respecto a B . Luego $\alpha_1, \dots, \alpha_n$ son las coordenadas de $\mathbf{x}$ respecto a B , y el vector

$$\boldsymbol{\alpha} = \begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix} \in \mathbb{R}^n$$



es el vector de coordenadas/representación de coordenadas de $\mathbf{x}$ con respecto a la base ordenada B .

Reto: En 5 minutos complete el Reto 08 y visualice en qué consiste una base.

Tips:

- Siga las instrucciones del reto.
- Con ayuda del instructor tenga una visualización geométrica de la función de una base.

Resultado Esperado:



Solución:

```
vec = lambda b: np.dot(b,np.vstack([2,3]))

b_base2 = np.vstack([[1,1],[-1,1]])
vec(e_base)

plt.axis([-scale/2,scale/2,-scale/2,scale/2])
plt.quiver(*origen,*e_base[:,0], scale = scale, color ="r")
plt.quiver(*origen,*e_base[:,1], scale = scale, color ="r")
plt.quiver(*origen,*b_base2[:,0], scale = scale,color="g")
plt.quiver(*origen,*b_base2[:,1], scale = scale,color="g")
plt.quiver(*origen, *vec(e_base), width=.01,scale=scale,color="k")
plt.quiver(*origen, *vec(b_base2), width=.01, scale=scale,color="k");
plt.quiver(*origen, *np.dot(b_base2,np.vstack([-1/2,5/2])), width=.007, scale=scale, color="gold")
plt.show()
```

Matriz de Transformación

Definición (Matriz de Transformación). Considere espacios vectoriales V, W con sus respectivas bases ordenadas $B = (\mathbf{b}_1, \dots, \mathbf{b}_n)$ y $C = (\mathbf{c}_1, \dots, \mathbf{c}_m)$. Mas aun, se considera un mapeo lineal $\Phi: V \rightarrow W$. Para $j \in \{1, \dots, n\}$,

$$\Phi(\mathbf{b}_j) = \alpha_{1,j}\mathbf{c}_1 + \dots + \alpha_{m,j}\mathbf{c}_m = \sum_{i=1}^m \alpha_{ij}\mathbf{c}_i$$

es la única representación de $\Phi(\mathbf{b}_j)$ respecto a C . Entonces, se denomina a la matriz de $m \times n$ como $\mathbf{A}_\Phi$, cuyos elementos están dados por

$$\mathbf{A}_\Phi(i, j) = \alpha_{i,j},$$

la transformación matricial de Φ (respecto a las bases ordenadas B de V y C de W).

Ejemplo (Matriz de Transformación).

Considere un homomorfismo $\Phi: V \rightarrow W$ y las bases ordenadas $B = (\mathbf{b}_1, \dots, \mathbf{b}_3)$ de V y $C = (\mathbf{c}_1, \dots, \mathbf{c}_4)$ de W . Con

$$\Phi(\mathbf{b}_1) = \mathbf{c}_1 - \mathbf{c}_2 + 3\mathbf{c}_3 - \mathbf{c}_4$$

$$\Phi(\mathbf{b}_2) = 2\mathbf{c}_1 + \mathbf{c}_2 + 7\mathbf{c}_3 + 2\mathbf{c}_4$$

$$\Phi(\mathbf{b}_3) = 3\mathbf{c}_2 + \mathbf{c}_3 + 4\mathbf{c}_4$$

La matriz de transformación $\mathbf{A}_\Phi$ respecto a B y C satisface $\Phi(\mathbf{b}_k) = \sum_{i=1}^4 \alpha_{ik} \mathbf{c}_i$ para $k = 1, \dots, 3$ y esta dada por

$$\mathbf{A}_\Phi = [\alpha_1, \alpha_2, \alpha_3] = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \\ 3 & 7 & 1 \\ -1 & 2 & 4 \end{bmatrix}$$




Donde los $\alpha_j, j = 1, 2, 3$ son los vectores coordenadas de $\Phi(\mathbf{b}_j)$ respecto a C .

Reto: En 5 minutos complete el Reto 09 y observe la función de una transformación lineal.

Tips:

- Siga las instrucciones del reto.
- Pregunte al instructor por dudas de código y en el funcionamiento de la transformación.

Resultado Esperado:



Solución:

```
# Se plantean las matrices de transformación
A1 = lambda theta: np.vstack([[np.cos(theta), -np.sin(theta)],
                               [np.sin(theta), np.cos(theta)]])

A2 = np.vstack([[2,0],
                [0,1]])

A3 = np.vstack([[3,-1],
                [1,-1]])*(1/2)

A1(np.pi/4)
```

```
# Se aplican las transformaciones
A1T = np.dot(A1(np.pi/4),original.T).T # Hay que trasponer nuevamente
A2T = np.dot(A2,original.T).T
A3T = np.dot(A3,original.T).T
```

```
# Graficar Transformacion A1
plt.axis([-scale/2,scale/2,-scale/2,scale/2])
plt.scatter(A1T[:,0],A1T[:,1], c='blue')
plt.show()
```

```
# Graficar Transformacion A2
plt.axis([-scale/2,scale/2,-scale/2,scale/2])
plt.scatter(A2T[:,0],A2T[:,1], c='green')
plt.show()
```

```
# Graficar Transformacion A3
plt.axis([-scale/2,scale/2,-scale/2,scale/2])
plt.scatter(A3T[:,0],A3T[:,1], c='pink')
plt.show()
```

Cambio de base

Definición (Cambio de Base). Para un mapeo lineal $\Phi: V \rightarrow W$, bases ordenadas

$$B = (\mathbf{b}_1, \dots, \mathbf{b}_n), \quad \tilde{B} = (\tilde{\mathbf{b}}_1, \dots, \tilde{\mathbf{b}}_n)$$

de V y

$$C = (\mathbf{c}_1, \dots, \mathbf{c}_m), \quad \tilde{C} = (\tilde{\mathbf{c}}_1, \dots, \tilde{\mathbf{c}}_m)$$

de W , y una matriz de transformación $\mathbf{A}_\Phi$ de Φ respecto a B y C , su correspondiente matriz de transformación $\tilde{\mathbf{A}}_\Phi$ respecto a las bases $\tilde{B}$ y $\tilde{C}$ es

$$\tilde{\mathbf{A}}_\Phi = \mathbf{T}^{-1} \mathbf{A}_\Phi \mathbf{S}$$

donde $\mathbf{S} \in \mathbb{R}^{n \times n}$ es una matriz de transformación que mapea coordenadas respecto a $\tilde{B}$ a coordenadas respecto a B , y $\mathbf{T} \in \mathbb{R}^{m \times m}$ es la matriz de transformación que mapea coordenadas respecto a $\tilde{C}$ a coordenadas respecto a C .

Definición (Equivalencia). Dos matrices $A, \tilde{A} \in \mathbb{R}^{m \times n}$ son equivalentes si existen matrices regulares $S \in \mathbb{R}^{n \times n}$ y $T \in \mathbb{R}^{m \times m}$, tal que $\tilde{A} = T^{-1}AS$.

Definición (Similaridad). Dos matrices $A, \tilde{A} \in \mathbb{R}^{n \times n}$ son similares si existe una matriz regular $S \in \mathbb{R}^{n \times n}$ con $\tilde{A} = S^{-1}AS$.



Reto: en 5 minutos complete el Reto 10. Observe cómo se calcula el cambio de base de una matriz de transformación.

Tips:

- Siga las instrucciones del Reto 10.
- Analice la teoría y los elementos necesarios para realizar un cambio de base.
- Pregunte sus dudas.

Resultado Esperado:

```
[[1 0 1]
 [1 1 0]
 [0 1 1]]
[[1 1 0 1]
 [1 0 1 0]
 [0 1 1 0]
 [0 0 0 1]]
```

```
array([[ -4.,  -4.,  -2.],
       [  6.,   0.,   0.],
       [  4.,   8.,   4.],
       [  1.,   6.,   3.]])
```

Solución:

```
# Se definen las matrices
Aphi = np.vstack([[1,2,0], [-1,1,3], [3,7,1], [-1,2,4]])
B = np.eye(3)
C = np.eye(4)
B2 = np.vstack([[1,0,1], [1,1,0], [0,1,1]]) #
C2 = np.vstack([[1,1,0,1], [1,0,1,0], [0,1,1,0], [0,0,0,1]])

# Se definen las matrices de representación de coordenadas
for i in range(B.shape[0]):
    S[:,i] = npl.solve(B,B2[:,i])

for i in range(C.shape[0]):
    T[:,i] = npl.solve(C,C2[:,i])

print(S)
print(T)
```

```
Aphi2 = np.dot(npl.inv(T), np.dot(Aphi, S))
Aphi2
```


Imagen y Kernel

Definición (Imagen y Kernel). Para $\Phi: V \rightarrow W$, se define el kernel/espacio nulo

$$\ker(\Phi) := \Phi^{-1}(\mathbf{0}_W) = \{\mathbf{v} \in V: \Phi(\mathbf{v}) = \mathbf{0}_W\}$$

y la imagen

$$\text{Im}(\Phi) := \Phi(V) = \{\mathbf{w} \in W | \exists \mathbf{v} \in V: \Phi(\mathbf{v}) = \mathbf{w}\}.$$



(Espacio Nulo y Espacio Columna). Considere una matriz $\mathbf{A} \in \mathbb{R}^{m \times n}$ y un mapeo lineal $\Phi: \mathbb{R}^n \rightarrow \mathbb{R}^m$, $\mathbf{x} \rightarrow \mathbf{Ax}$.

- Para $\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_n]$, donde $\mathbf{a}_i$ son las columnas de A , se obtiene

$$\begin{aligned} \text{Im}(\Phi) = \{\mathbf{Ax}: \mathbf{x} \in \mathbb{R}^n\} &= \left\{ \sum_{i=1}^n x_i \mathbf{a}_i : x_1, \dots, x_n \in \mathbb{R} \right\} \\ &= \text{span}[\mathbf{a}_1, \dots, \mathbf{a}_n] \subseteq \mathbb{R}^m \end{aligned}$$

i.e., la imagen es el span de las columnas de $\mathbf{A}$, también conocido como espacio columna.

- $\text{rank}(\mathbf{A}) = \dim(\text{Im}(\Phi))$.
- El kernel/espacio nulo es la solución general al sistema de ecuaciones lineales $\mathbf{Ax} = \mathbf{0}$ y captura todas las posibles combinaciones lineales de $\mathbb{R}^n$ que produce $\mathbf{0} \in \mathbb{R}^m$.

Reto: En 5 minutos complete el Reto 11 para calcular los subespacios de la imagen y kernel de una transformación lineal

Tips:

- Siga las instrucciones del Reto.
- Utilice los conceptos aprendidos anteriormente: eliminación Gaussiana, el truco de -1, rango.

Resultado Esperado:

```
2
array([[ 1. ,  0. ,  0. ,  1. ],
       [ 0. ,  1. , -0.5, -0.5],
       [ 0. ,  0. , -1. ,  0. ],
       [ 0. ,  0. ,  0. , -1. ]])
```

```
array([[ 0. ,  1. ],
       [-0.5, -0.5],
       [-1. ,  0. ],
       [ 0. , -1. ]])
```

Solución:

```
# Definimos el mapeo
Phi = Matrix([[1,2,-1,0],[1,0,0,1]])
print(Phi)
PhiRef = np.array(Phi.rref()[0]).astype(np.float64)
Matrix(PhiRef)

image_PhiRef = npl.matrix_rank(PhiRef)
print(image_PhiRef)

# Truco de -1
PhiRef = np.insert(PhiRef,2,np.array([0,0,-1,0]),0)
PhiRef = np.insert(PhiRef,3,np.array([0,0,0,-1]),0)
PhiRef

base_PhiRef = PhiRef[:,2:4]
base_PhiRef
```

Teorema Fundamental de Mapeos Lineales

Para espacios vectoriales V, W y un mapeo lineal $\Phi: V \rightarrow W$ se satisface que

$$\dim(\ker(\Phi)) + \dim(\text{Im}(\Phi)) = \dim(V).$$

En consecuencia se satisface:

- Si $\dim(\text{Im}(\Phi)) < \dim(V)$, entonces $\ker(\Phi)$ es no trivial, i.e., el kernel contiene mas elementos además del $\mathbf{0}_V$ y $\dim(\ker(\Phi)) \geq 1$.
- Si $\mathbf{A}_\Phi$ es una matriz de transformación de Φ con respecto a una base ordenada y $\dim(\text{Im}(\Phi)) < \dim(V)$, entonces el sistema de ecuaciones $\mathbf{A}_\Phi \mathbf{x} = \mathbf{0}$ tiene soluciones infinitas.
- Si $\dim(V) = \dim(W)$, entonces se mantiene que
 - Φ es inyectiva
 - Φ es sobreyectiva
 - Φ es biyectiva

Espacios Afines



ACTUMLOGOS

DESARROLLANDO HABILIDADES TECNOLÓGICAS

Espacios Afines

Los espacios afines son espacios que presentan un offset del origen, i.e., son espacios que no son subespacios vectoriales.

Definición (Subespacio Afín). Sea V un espacio vectorial, $\mathbf{x}_0 \in V$ y $U \subseteq V$ un subespacio. Luego el subconjunto

$$\begin{aligned} L &= \mathbf{x}_0 + U := \{\mathbf{x}_0 + \mathbf{u} : \mathbf{u} \in U\} \\ &= \{\mathbf{v} \in V \mid \exists \mathbf{u} \in U : \mathbf{v} = \mathbf{x}_0 + \mathbf{u}\} \subseteq V \end{aligned}$$

se le denomina subespacio afín o variedad lineal de V . U se le conoce como dirección o espacio dirección, y $\mathbf{x}_0$ se conoce como punto de soporte.

Espacios afines son usualmente descritos por parámetros: Considere un espacio afín $L = \mathbf{x}_0 + U$ de V de dimensión k . Si $(\mathbf{b}_1, \dots, \mathbf{b}_k)$ es una base ordenada de U , entonces cada elemento $\mathbf{x} \in L$ puede ser descrito de manera única por

$$\mathbf{x} = \mathbf{x}_0 + \lambda_1 \mathbf{b}_1 + \dots + \lambda_k \mathbf{b}_k$$

Donde $\lambda_1, \dots, \lambda_k \in \mathbb{R}$. Esta representación es llamada ecuación paramétrica de L con vectores direccionales $\mathbf{b}_1, \dots, \mathbf{b}_k$ y parámetros $\lambda_1, \dots, \lambda_k$.


- Un espacio afín de una dimensión se le conoce como líneas.
- Un espacio afín de dos dimensiones se le conoce como plano.
- Un espacio afín de tres o mas dimensiones se le conoce como hiperplano.

Reto: En 5 minutos complete el reto 12 y visualice el concepto de un subespacio afín.

Resultado Esperado:

Tips:

- Considere un espacio afín como la ecuación de un hiperplano.



Solución:

```
# Graficar un espacio afín
scale = 10
origen = np.array([0,0])
plt.rcParams[ "figure.figsize" ] = (10,10)
plt.axis([-scale/2,scale/2,-scale/2,scale/2])

# Data setup.
lambda1 = 1
x0 = np.array([-1,1])      # Punto de soporte
x1 = np.array([3,.5])      # Punto que define la dirección
val = x0+lambda1*x1        # Línea
x1s = np.vstack([k*x1 for k in np.linspace(-4,4,250)]) # Crear una línea en dirección de x1

# Graficando espacio afín
val2 = np.vstack([x0+l*x1 for l in np.linspace(-4,4,250)])
plt.plot(x1s[:,0],x1s[:,1],color="b")
plt.plot(val2[:,0],val2[:,1],color="r")

# Graficar vectores
plt.quiver(*origen, *x1, scale=scale, color="k")
plt.quiver(*origen, *x0, scale=scale, color="blueviolet")
plt.quiver(*origen, *val, scale=scale, color="orange")

plt.legend(["$x_1\backslash\lambda$", "L = x_0 + \backslash\lambda x_1$", "$x_1$", "$x_0$", "$y$"]);
```

Definición (Mapeos Afines). Para dos espacios vectoriales V, W , un mapeo $\Phi: V \rightarrow W$, y $\mathbf{a} \in W$, el mapeo

$$\begin{aligned}\phi: V &\rightarrow W \\ \mathbf{x} &\mapsto \mathbf{a} + \Phi(\mathbf{x})\end{aligned}$$

es un mapeo afín de V a W . El vector $\mathbf{a}$ se le conoce como vector de traslado de ϕ .

Cada mapeo afín $\phi: V \rightarrow W$ es una composición de un mapeo lineal $\Phi: V \rightarrow W$ y una traslación $\tau: W \rightarrow W$ en W , tal que $\phi = \tau \circ \Phi$.

- Libros de Algebra Lineal
 - Stanley I. Grossman, *Algebra Lineal*, 2007. <http://up-rid2.up.ac.pa:8080/xmlui/bitstream/handle/123456789/1326/%C3%81lgebra%20lineal.pdf?sequence=1&isAllowed=y>
 - Peter Lancaster, Miron Tismenetsky, *The Theory of Matrices with Applications* <https://www.scribd.com/document/263962281/P-Lancaster-The-Theory-of-Matrices-2nd-ED-pdf>
- Aplicaciones en teoría de sistemas lineales
 - Chi-Tsong Chen, *Linear System Theory and Design*, 1999 http://ebadi.profcms.um.ac.ir/imagesm/474/stories/modern_control/chen%20c%20t%20linear%20system%20theory%20and%20design.pdf

Conclusión Final

- El álgebra lineal provee de herramientas y terminología básica para entender el funcionamiento de los algoritmos de ML.
- Cada tema visto (vectores, matrices, independencia lineal, bases) definen la geometría de un espacio vectorial.
- En especial, la independencia lineal y bases motivan los algoritmos de reducción de dimensionalidad.
- Se sostiene que los algoritmos de ML están basados en resolver un problema de geometría.

Glosario

- Vector
- Matrices
- Matriz Inversa
- Transpuesta
- Linealmente dependiente
- Espacio Vectorial
- Grupo
- Subespacio Vectorial
- Rango
- Imagen
- Kernel
- Base
- Span
- Espacio nulo
- Combinacion lineal
- Mapeos Lineales
- Matriz de transformación
- Espacio afin
- Subespacio afin
- Least-Mean Squares (LMS)